

DOCUMENT DE RÉFÉRENCE — ÉDITION 2026

Les de Hack The Harvest.

Chaque sujet est présenté avec son énoncé métier, son livrable attendu, sa **procédure de validation jury** en live, l'approche technique étape par étape, les sources de données qualifiées par niveau d'effort, les critères d'évaluation spécifiques, et les pièges fréquents. Document à garder ouvert pendant les 72 heures.

Sources de données : trois niveaux d'effort

Toutes les sources listées sont **100 % gratuites** et accessibles sans aucun moyen de paiement. Elles sont classées par niveau de friction administrative. Les sources Tier 3 demandent plus de démarches mais offrent un avantage compétitif réel — **le jury valorise les équipes qui mobilisent ces ressources.**

T1 Tier 1 — Zéro friction

Aucune inscription. Accès immédiat à l'URL.

T2 Tier 2 — Inscription simple

Email + mot de passe, parfois vérification SMS.

T3 Tier 3 — Effort récompensé

Compte cloud, validation académique, formulaire.

01

TRACK · VISION SATELLITE + CLASSIFICATION

Cartographie intelligente des oliveraies tunisiennes

Difficulté : ★★☆☆☆ Élevée — pipeline en deux étages

🎯 ÉNONCÉ MÉTIER

Personne en Tunisie ne dispose d'une carte fine, actualisée et **qualifiée** des oliveraies. Les statistiques officielles agrégées par gouvernorat ne distinguent pas les systèmes de conduite, alors que les rendements et besoins en eau sont radicalement différents : **1-3 t/ha en extensif sec, 4-8 t/ha en intensif, 10-15 t/ha en hyper-intensif irrigué**. Une carte qui détecte ET qualifie chaque oliveraie devient un actif stratégique inédit pour la planification logistique, le ciblage commercial AgriManager, l'allocation d'eau et la prévision de production nationale.

🚀 MISSION ÉTUDIANT

Construire un pipeline complet qui, à partir d'un périmètre dessiné sur une carte, **détecte toutes les oliveraies présentes** (segmentation Sentinel-2) puis **classifie chacune** en extensif / intensif / hyper-intensif (signature spectrale et texturale).

📦 LIVRABLE ATTENDU

Une application web avec une carte Leaflet permettant de dessiner un polygone, une API REST qui exécute le pipeline complet (détection + classification), et un export GeoJSON téléchargeable des oliveraies annotées.

🏛️ PROCÉDURE DE VALIDATION PAR LE JURY

📝 DÉMO EN LIVE · LE JURY TESTE L'APP

Le jour de la présentation, un membre du jury ouvre l'app et exécute le scénario suivant :

- 1 **Le jury dessine un grand polygone** sur la carte de Tunisie (zone au choix : 50 km² au Cap Bon, Sahel, Sfax, etc.)

- 2 Il clique sur **"Analyser cette zone"** → l'API exécute la détection puis la classification en arrière-plan
- 3 En quelques secondes, la carte affiche les **oliveraies détectées colorées par système** :
 ● vert = extensif ● jaune = intensif ● rouge = hyper-intensif
- 4 **Tableau récapitulatif** : nombre d'oliveraies détectées, surface totale, répartition par système, surface moyenne
- 5 Le jury peut **télécharger un GeoJSON** avec les polygones annotés pour vérifier dans QGIS

Endpoint API attendu :

```
POST /api/cartographier { "polygone_perimetre": <GeoJSON Polygon>, "date":
"2026-06-15" } // Response { "oliveraies": [ { "polygone": <GeoJSON>,
"systeme": "intensif", "confiance": 0.87, "surface_ha": 12.4 }, ... ],
"stats": { "total_oliveraies": 47, "surface_totale_ha": 612.3, "repartition":
{ "extensif": 28, "intensif": 15, "hyper_intensif": 4 } } }
```

☰ APPROCHE TECHNIQUE

Pipeline en **deux étages** :

- 1 **[Étage 1 — Segmentation]** Splitter les JSON oliviers EZZAYRA en train (70%) / val (15%) / test (15%) avec **stratification spatiale** par gouvernorat — ne jamais mélanger des polygones d'une même zone.
- 2 **[Étage 1]** Pour chaque polygone, télécharger les bandes Sentinel-2 L2A (B2, B3, B4, B8, B11) sur la période **mai-juin** où le contraste olivier/sol est maximal. Filtrer les nuages avec la masque SCL.
- 3 **[Étage 1]** Entraîner un U-Net avec backbone ResNet pré-entraîné (segmentation_models_pytorch). Loss = BCE + Dice combinées.
- 4 **[Étage 2 — Classification]** Sur chaque polygone détecté, extraire features : NDVI moyen/max/min, amplitude saisonnière, NDWI, NDRE, densité de canopée (FAPAR/LAI).
- 5 **[Étage 2]** Calculer features de **texture GLCM** sur les images haute saison — la régularité géométrique des hyper-intensifs en haies se voit nettement à 10 m.

- 6 **[Étage 2]** Random Forest ou XGBoost multi-classe (E/I/HI). Validation par **CV spatiale** obligatoire.
- 7 **[Démo]** FastAPI + frontend Leaflet avec outil de dessin de polygone (Leaflet.draw). Limiter la taille max du polygone (ex: 100 km²) pour la démo live.

SOURCES DE DONNÉES

T1

JSON oliviers EZZAYRA + attribut système — vérité terrain

Fourni dans le pack hackathon. Donnée introuvable ailleurs — c'est ce qui rend le sujet unique.

 **Pack fourni**

T2

Copernicus Data Space Ecosystem (Sentinel-2 L2A)

Inscription par email seulement, pas de carte bancaire. 10 000 crédits openEO gratuits par mois.

 **Accéder**

T3

Google Earth Engine

Compte Google + projet "noncommercial". Catalogue Sentinel + Landsat + MODIS unifié, exécution cloud.

 **S'inscrire**

T3

Planet NICFI — imagerie 4.7 m mensuelle

Compte NICFI gratuit pour usage non-commercial / recherche. **Permet la distinction fine des haies hyper-intensives.**

 **S'inscrire**

T1

OpenStreetMap Overpass API

Aucune inscription. Tag `landuse=orchard` pour candidats à l'inférence nationale.

 **Accéder**

T1

SoilGrids 250m

Aucune inscription. Texture, pH, CEC. Features de contexte pour la classification.

 **Accéder**

CRITÈRES JURY SPÉCIFIQUES

ÉVALUATION SUJET 01

- ✓ IoU ≥ 0.65 sur la détection (étage 1)
- ✓ F1 macro ≥ 0.70 sur la classification 3 classes (étage 2)

- ✓ Démo live fonctionnelle sur une zone non-vue à l'entraînement
- ✓ Matrice de confusion 3×3 affichée et commentée
- ✓ Validation spatiale appliquée (pas seulement aléatoire)
- ✓ Latence acceptable pour la démo (< 30 s sur polygone de 50 km²)

⚠ PIÈGES À ÉVITER

- ⚠ **Fuite de données spatiale** : ne jamais mettre des polygones voisins dans train et test — l'autocorrélation spatiale gonfle artificiellement les scores.
- ⚠ **Confusion intensif/hyper-intensif** : les deux peuvent avoir des NDVI similaires en pleine saison. Différencier par texture et amplitude saisonnière.
- ⚠ **Déséquilibre des classes** : probablement plus d'extensifs que d'hyper-intensifs. Utiliser `class_weight` ou SMOTE.
- ⚠ **Période d'acquisition** : en hiver, l'olivier ressemble spectralement à beaucoup d'autres cultures. Privilégier mai-juin.
- ⚠ **Démo trop lente** : précalculer un cache des images Sentinel sur la zone démo pour répondre en quelques secondes.

02

TRACK · PRÉDICTION DE RENDEMENT

Modèle prédictif de tonnage à la parcelle de tomate

Difficulté : ★★☆☆☆ Élevée — feature engineering exigeant

🎯 ÉNONCÉ MÉTIER

La tomate est une culture stratégique pour la Tunisie : transformation industrielle (concentré, double-concentré, conserves), marché frais et export. Le rendement varie fortement selon l'irrigation, le sol, la météo et le calendrier de plantation. Une **prédiction fiable du tonnage 30-45 jours avant récolte** est un actif stratégique pour : le financement agricole (banques, micro-finance), l'assurance récolte, la planification logistique des conserveries, et le pré-positionnement commercial.

🚀 MISSION ÉTUDIANT

Construire un modèle qui prédit le tonnage d'une parcelle de tomate à partir de l'historique NDVI et météo de la saison. **Vérité terrain : les tonnages réels par parcelle fournis par EZZAYRA** — donnée rare en Tunisie, c'est ce qui rend ce sujet scientifiquement crédible.

📦 LIVRABLE ATTENDU

Une API REST qui prend en entrée un JSON parcelle (polygone + date de prédiction) et retourne le tonnage prédit avec intervalle de confiance et explication SHAP. Un dashboard qui visualise la prédiction sur la carte et explique les facteurs déterminants.

⚖️ PROCÉDURE DE VALIDATION PAR LE JURY

📝 DÉMO EN LIVE · LE JURY TESTE L'API

Le jury fournit un JSON de parcelle et observe la réponse complète :

- 1 Le jury **fournit un JSON parcelle** (test de generalization sur parcelle non-vue à l'entraînement) via Postman ou l'interface web
- 2 L'API exécute la collecte automatique des features (NDVI Sentinel-2 + météo Open-Meteo + sol SoilGrids)

- 3 Réponse : **tonnage prédit en tonnes, intervalle de confiance à 95%**, et **top features SHAP** qui expliquent la prédiction
- 4 Le dashboard affiche une **visualisation interactive** : courbe NDVI saisonnière, graphique SHAP, carte de la parcelle

Endpoint API attendu :

```
POST /api/predire-rendement { "parcelle": { "id": "P_2026_142", "polygone":
<GeoJSON Polygon>, "date_plantation": "2026-04-15", "variete": "Rio Grande"
}, "date_prediction": "2026-08-10" } // Response { "tonnage_predit_t": 52.3,
"intervalle_confiance_95": [46.1, 58.7], "top_features_shap": [ {"feature":
"NDVI_max_juillet", "impact": +8.4}, {"feature": "cumul_pluie_juin",
"impact": -3.1}, {"feature": "jours_stress_thermique", "impact": -2.7} ],
"date_recolte_estimee": "2026-09-22" }
```

☰ APPROCHE TECHNIQUE

- 1 Pour chaque parcelle, calculer une **série NDVI Sentinel-2** (10-15 dates par saison) et des **agréats météo** (cumul pluie, jours de stress >35°C, ET₀ cumulé, GDD).
- 2 **Feature engineering temporel par phase phénologique tomate** : levée, croissance végétative, floraison, fructification, maturation. Chaque phase a son propre indicateur.
- 3 Ajouter des **features sol** (SoilGrids) : texture, pH, capacité de rétention en eau.
- 4 **Modèles** : LightGBM ou XGBoost en baseline, puis tester un LSTM si la série temporelle le permet.
- 5 **Validation croisée spatiale** (K-Fold groupé par région) — la CV temporelle classique ne suffit pas car les parcelles voisines sont corrélées.
- 6 **SHAP values** obligatoires pour expliquer chaque prédiction. C'est le critère d'adoption terrain le plus important.
- 7 **Calibration de l'intervalle de confiance** : conformal prediction ou quantile regression — pas juste une valeur ponctuelle.

📊 SOURCES DE DONNÉES

T1

Parcelles + tonnages tomate EZZAYRA — labels

Fourni dans le pack hackathon. Vérité terrain. Multi-saisons.

 **Pack fourni**

T1

Open-Meteo (météo + ET₀)API REST gratuite, **aucune clé requise**, ET₀ calculé directement par l'API. 80 ans d'historique. **Docs API**

T1

NASA POWER (climato 40 ans)

Aucune inscription. Variables agro complètes. Indispensable pour calculer GDD.

 **Docs API**

T2

Sentinel Hub Process API (NDVI rapide)

Compte CDSE + génération OAuth. Plus performant qu'OData pour des time series.

 **Docs API**

T1

SoilGrids 250m

Aucune inscription. Texture, pH, CEC, carbone organique. Features sol essentielles.

 **Accéder**

T3

AgERA5 — météo agro réanalysée 0.1°

Compte Climate Data Store + acceptation conditions. Variables agro horaires sur 40 ans, qualité supérieure.

 **S'inscrire** **CRITÈRES JURY SPÉCIFIQUES****ÉVALUATION SUJET 02**

- ✓ MAPE par classe de rendement (faible/moyen/fort) — pas seulement RMSE global
- ✓ SHAP values disponibles dans la démo, expliquables à un non-data scientist
- ✓ Validation spatiale (CV par groupe géographique) appliquée
- ✓ Intervalle de confiance calibré (pas juste une valeur ponctuelle)
- ✓ Démo API live fonctionnelle sur parcelle non-vue à l'entraînement

 PIÈGES À ÉVITER

-  **Fuite temporelle :** ne jamais utiliser de features postérieures à la date de prédiction.

- ⚠ **Métrique RMSE seule :** trompeuse quand les classes sont déséquilibrées. MAPE par tranche est plus honnête.
- ⚠ **Saisonnalité ignorée :** en Tunisie, la tomate de saison ouverte (printemps-été) et celle de plein champ d'hiver sous abri ont des rendements très différents — les distinguer si l'info est dans le JSON.
- ⚠ **Variétés mélangées :** les variétés industrielles (Rio Grande, Heinz) ont des potentiels très différents des variétés de bouche.

03

TRACK · STRESS HYDRIQUE & SANTÉ DES CULTURES

Détection précoce d'anomalies sur oliveraies

Difficulté : ★★☆☆ Modérée — apprentissage non-supervisé accessible

🎯 ÉNONCÉ MÉTIER

Quand une oliveraie souffre (stress hydrique, attaque de ravageurs, problème d'irrigation), **le stress visible apparaît trop tard** — les pertes sont déjà actées. Une détection 2-3 semaines en amont permet à l'agriculteur d'intervenir : irrigation d'appoint, traitement ciblé, vérification du système. **Détecter ces anomalies sans avoir besoin de labels "stressé/sain"** est un sujet typiquement non-supervisé qui colle aux données disponibles.

🚀 MISSION ÉTUDIANT

Sur les oliveraies connues d'EZZAYRA, construire un système de détection d'anomalie qui alerte quand le NDVI d'une parcelle décroche par rapport à son comportement historique attendu, compte tenu de la météo locale.

📦 LIVRABLE ATTENDU

Un dashboard cartographique Leaflet qui affiche en temps quasi-réel chaque parcelle en **vert / orange / rouge** selon son score d'anomalie, plus une API qui retourne ce statut pour une parcelle donnée.

🏛️ PROCÉDURE DE VALIDATION PAR LE JURY

📝 DÉMO EN LIVE · DIAGNOSTIC D'UNE PARCELLE

Le jury fournit le JSON d'une oliveraie et observe le diagnostic complet :

- 1 Le jury **fournit un JSON oliveraie** (test sur parcelle réelle) via l'interface ou Postman
- 2 L'API exécute la collecte NDVI + météo des dernières semaines et calcule **l'écart par rapport au comportement attendu**

- 3 Réponse : **statut vert/orange/rouge, anomaly score** numérique, **courbe NDVI observé vs attendu, explication textuelle**
- 4 Sur le dashboard cartographique, le jury voit la parcelle apparaître **colorée selon son statut** au milieu des autres oliveraies

Endpoint API attendu :

```
POST /api/diagnostic-anomalie { "oliveraie": { "id": "0_2026_307",  
"polygone": <GeoJSON>, "systeme": "intensif" }, "date": "2026-07-15" } //  
Response { "statut": "orange", "anomaly_score": 2.4, "ndvi_observe": [0.42,  
0.45, 0.41, 0.37, 0.34], "ndvi_attendu": [0.48, 0.50, 0.52, 0.51, 0.50],  
"explication": "NDVI 26% en dessous attendu sur 3 semaines, malgré pluie  
normale. Stress probable - vérifier irrigation.", "recommandation":  
"Inspection visuelle dans 48h" }
```

☰ APPROCHE TECHNIQUE

- 1 Pour chaque parcelle, construire un **"NDVI attendu"** en fonction de (date saisonnière, pluviométrie cumulée, température cumulée, système de conduite). Régression Ridge ou Prophet.
- 2 Calculer un **anomaly score** = écart normalisé entre NDVI observé et NDVI attendu sur fenêtre glissante 3 semaines.
- 3 **Seuiller dynamiquement** en vert / orange / rouge avec des seuils basés sur les quantiles historiques de la parcelle.
- 4 **Dashboard Leaflet** avec couches : parcelles colorées, popup détail (courbe NDVI réel vs attendu), filtre par gouvernorat / système.
- 5 **Bonus** : ajouter la **température de surface (LST)** de Landsat 8/9 thermique pour détecter le stress thermique avant qu'il n'apparaisse en NDVI.
- 6 **Module d'explication** : générer automatiquement un texte court qui explique pourquoi la parcelle est en alerte.

📊 SOURCES DE DONNÉES

JSON oliviers EZZAYRA

T1

📁 Pack fourni

Fourni dans le pack hackathon. Population de référence pour le baseline saisonnier.

Sentinel-2 série temporelle

T2

Via Copernicus Data Space Ecosystem. 5-10 ans de profondeur historique nécessaires pour calibrer le baseline.

[Accéder](#)

CHIRPS — pluviométrie satellite

T1

Public domain, aucune inscription. 0.05° de résolution, 1981-aujourd'hui.
Plus fiable que les stations sol tunisiennes en zone rurale.

[Accéder](#)

Open-Meteo Archive API

T1

80 ans de météo historique sans inscription. Idéal pour features de calage.

[Docs API](#)

MODIS LST (température de surface)

T3

NASA Earthdata Login + token. Donnée 1 km résolution depuis 2000.
Bonus : détection du stress thermique pré-NDVI.

[S'inscrire](#)

Google Earth Engine — accès unifié

T3

Compte Google + projet noncommercial. Permet de combiner MODIS LST et Sentinel-2 NDVI dans un seul script.

[S'inscrire](#)

➦ CRITÈRES JURY SPÉCIFIQUES

ÉVALUATION SUJET 03

- ✓ Distinction claire entre vraie anomalie et bruit naturel saisonnier
- ✓ Module d'explication automatique fonctionnel et pertinent
- ✓ Dashboard fluide, lisible par un non-technique
- ✓ Démo API live sur oliveraie réelle
- ✓ Bonus pour intégration LST thermique (stress avant NDVI)

⚠ PIÈGES À ÉVITER

- ⚠ **Phénologie ignorée :** le NDVI d'un olivier varie naturellement entre saisons. Le baseline doit être saisonnier, pas global.

- ⚠ **Bruit pixel :** moyenner sur la parcelle entière, pas sur un seul pixel. Les pixels de bordure sont contaminés par le sol nu.
- ⚠ **Faux positifs après taille :** une chute de NDVI après taille est normale, pas une anomalie. Stratifier par mois et par système.
- ⚠ **Différence E/I/HI :** un extensif sec a naturellement un NDVI plus bas qu'un hyper-intensif. Le baseline doit être par système.

04

TRACK · IA CONVERSATIONNELLE MULTIMODALE

Assistant vocal oléicole en darija (vision + RAG)

Difficulté : ★★☆☆☆ Élevée — pile complète vision + ASR + RAG + LLM + TTS

🎯 ÉNONCÉ MÉTIER

Une grande partie des oléiculteurs tunisiens lisent peu, parlent dialecte, et n'ont pas accès régulier aux conseillers agricoles. **Un assistant vocal en darija couplé à la vision (photo de feuille) démocratise le conseil agronomique.** Mais attention : un chatbot agricole qui hallucine peut faire perdre une récolte ou empoisonner un agriculteur. **Ce sujet est autant un défi technique qu'un défi de sécurité.**

🚀 MISSION ÉTUDIANT

Construire un assistant multimodal qui répond en arabe tunisien aux questions des oléiculteurs, en se basant **strictement** sur (1) un corpus de PDF que l'équipe télécharge depuis les liens fournis (FAO, EPPO, CIHEAM), et (2) un classifieur de maladies de feuille d'olivier. **L'assistant doit refuser de répondre si l'information n'est pas dans le corpus — l'hallucination est interdite et pénalisée fortement par le jury (30 points).**

📦 LIVRABLE ATTENDU

Une PWA (Progressive Web App) ou app mobile qui :

- 📷 Prend une photo de feuille avec l'appareil photo du téléphone
- 🎤 Écoute la voix de l'agriculteur en darija (Whisper)
- 🔍 Classifie la photo (CNN entraîné sur PlantVillage olive disease) + cherche dans le corpus PDF
- 🔊 Répond vocalement en darija avec citation de la source
- 🛑 Refuse poliment quand le score de pertinence est trop bas

🏛️ PROCÉDURE DE VALIDATION PAR LE JURY

 DÉMO EN LIVE · SCÉNARIO D'UTILISATION RÉEL

Le jury simule un agriculteur qui consulte l'app sur son téléphone :

- 1 Le jury **prend une photo d'une feuille d'olivier malade** (échantillon physique apporté par les organisateurs ou photo téléchargée du dataset PlantVillage)
- 2 Il **pose une question vocale en darija** :
شنوة هاذي المرض اللي في زيتوني ؟
("c'est quoi cette maladie sur mon olivier ?")
- 3 L'app **transcrit la voix** (Whisper), **classifie la photo** (CNN), **cherche dans le corpus PDF**, et **génère une réponse textuelle en arabe** avec citation de la source
- 4 L'app **lit la réponse en darija** (TTS) — le jury écoute la qualité de prononciation et la pertinence du diagnostic
- 5 **Test de sécurité** : le jury pose une question hors-corpus (ex : "comment fertiliser mes amandiers ?"). L'app doit **refuser poliment** et orienter vers un conseiller

 EXEMPLES DE QUESTIONS TRAITÉES

السؤال بالدارجة	CE QUE FAIT L'APP
 + شنوة هاذي المرض اللي في زيتوني ؟	Photo → CNN classifie (œil de paon, anthracnose, verticilliose...) → fiche EPPO → réponse en darija
وقتاش نحشّش زيتوني ؟	Recherche dans corpus FAO/CIHEAM la fenêtre de taille recommandée → réponse vocale
كيفاش نعالج عين الطاووس ؟	Recherche dans EPPO les méthodes de lutte → réponse + renvoi vers conseiller pour dosages précis
شنوة الشركة اللي تشري طماطم في تونس ؟	Refus : hors-corpus oléicole → orientation vers conseiller

☰ APPROCHE TECHNIQUE

- 1 **Vision (CNN photo de feuille) :** entraîner sur PlantVillage olive disease (open dataset) ou utiliser un modèle pré-entraîné. Classes : sain, œil de paon, anthracnose, verticilliose, etc.
- 2 **ASR (Whisper) :** transcrire la voix darija en texte. Whisper-large gère bien l'arabe tunisien.
- 3 **Constitution du corpus :** télécharger les PDF des URLs fournies (FAO ECOCROP, EPPO Global Database, FAO Olive Production Manual, CIHEAM-IAMB Bari, Cahiers Agricultures CIRAD). Convertir PDF → texte → chunks de ~500 tokens.
- 4 **Indexation vectorielle :** embeddings multilingues (sentence-transformers `paraphrase-multilingual-MiniLM`), stockage FAISS ou ChromaDB.
- 5 **Récupération hybride :** recherche sémantique sur le corpus + injection du résultat de la classification photo.
- 6 **Garde-fou anti-hallucination :** si le score de pertinence top-1 < seuil, l'app répond "Je n'ai pas l'information dans ma base, contacte un conseiller agricole".
- 7 **LLM :** uniquement pour reformuler la réponse en darija à partir des passages trouvés. Prompt strict : "Ne réponds qu'à partir des extraits ci-dessous, ne complète pas avec tes propres connaissances".
- 8 **TTS :** synthèse vocale arabe (Coqui TTS ou edge-tts gratuits).

📄 SOURCES DE DONNÉES — CORPUS À SCRAPER / TÉLÉCHARGER

T1

PlantVillage Dataset (photos maladies feuilles)

Dataset open source. Contient des classes olive disease pour entraîner le CNN.

[🔗 GitHub](#)

T1

FAO ECOCROP — fiches culture olivier

Aucune inscription. Besoins climatiques, sol, eau pour l'olivier.

[🔗 Accéder](#)

EPPO Global Database

T1

Aucune inscription. Fiches maladies/ravageurs de l'olivier avec photos et fiches de gestion.

[🔗 Accéder](#)**FAO Olive Production Manual**

T1

PDF libre, référence mondiale oléiculture. À télécharger et indexer.

[🔗 Catalogue FAO](#)**CIHEAM-IAMB Bari — publications oléiculture**

T1

Centre de référence méditerranéen. Nombreuses publications libres en français/anglais sur l'olivier.

[🔗 Accéder](#)**Cahiers Agricultures (CIRAD)**

T1

Articles open access en français, contexte méditerranéen.

[🔗 Accéder](#)**Whisper (ASR open-source)**

T1

Code et poids gratuits sur GitHub. Whisper-large gère le dialecte tunisien.

[🔗 GitHub](#)**Coqui TTS / edge-tts**

T1

Synthèse vocale arabe gratuite, sans clé API. edge-tts utilise les voix Microsoft sans authentification.

[🔗 GitHub](#)**📌 CRITÈRES JURY SPÉCIFIQUES — ANTI-HALLUCINATION****ÉVALUATION SUJET 04 — PROTOCOLE DE TEST RENFORCÉ**

- ✓ Test de qualité : 5 questions vocales avec photos dont la réponse EST dans le corpus → l'app doit répondre correctement
- ✓ Test photo : 3 photos de feuilles malades (différentes maladies) → bon diagnostic CNN
- ✓ Test de sécurité : 3 questions piégées hors-corpus → l'app doit refuser poliment
- ✓ **Une seule hallucination = pénalité majeure de 30 points sur 100**
- ✓ Démo vocale fluide en darija devant le jury
- ✓ Latence réponse < 8 secondes sur question simple
- ✓ Citation systématique de la source dans la réponse

⚠️ PIÈGES À ÉVITER

- ⚠️ **Laisser le LLM "compléter" :** sans prompt strict et sans seuil de pertinence, le LLM hallucine systématiquement. Le prompt doit interdire l'usage des connaissances pré-entraînées.
- ⚠️ **Embeddings monolingues :** si l'index est en français mais la question en arabe, la recherche échoue. Utiliser un modèle multilingue.
- ⚠️ **Corpus trop petit :** moins de 50 documents = système qui refuse trop souvent. Viser 200-500 documents bien chunked.
- ⚠️ **Dosages précis :** ne jamais laisser l'app donner un dosage de pesticide précis — toujours renvoyer vers la fiche produit ou un conseiller. Risque légal.
- ⚠️ **CNN sur-entraîné :** PlantVillage est un dataset "lab" avec fond uniforme. Les vraies photos terrain ont du fouillis — augmenter avec data augmentation agressive.

★ SOURCES PREMIUM · TIER 3

L'effort de recherche, ça paie.

Ces sources demandent plus de démarches administratives — création de compte cloud, formulaire de validation, génération de tokens. Mais elles offrent des données premium qui font une différence visible dans les résultats. **Le jury distingue les équipes qui les mobilisent.**

AgERA5 T3

Météo agro réanalysée 0.1°, 40 ans, qualité supérieure. Variables agro horaires (ET₀, GDD, déficit hydrique).

cds.climate.copernicus.eu 

Google Earth Engine T3

Tout le catalogue Sentinel + Landsat + MODIS dans un seul environnement cloud, exécution serverless. Community tier gratuit, sans facturation.

earthengine.google.com 

NASA Earthdata T3

MODIS LST, Landsat 8/9 thermique, MODIS LAI/FAPAR. URS account + token.

Planet NICFI T3

Imagerie PlanetScope 4.7 m de résolution, mensuelle, gratuite pour

Indispensable pour le stress thermique.

usage non-commercial / recherche.

urs.earthdata.nasa.gov 

planet.com/nicfi 

WaPOR FAO T3

Productivité de l'eau Afrique/Moyen-Orient, calibré spécifiquement agriculture. Compte WaPOR + clé API.

wapor.apps.fao.org 

Sentinel Hub Process API T2/T3

Compte CDSE + génération OAuth client. Plus performant qu'OData pour des time series.

docs.sentinel-hub.com 

Kaggle (datasets oliviers) T2

Inscription email + vérification SMS. Versions augmentées des datasets oliviers de meilleure qualité.

kaggle.com/datasets 

Microsoft Planetary Computer T3

Catalogue Sentinel + Landsat + datasets globaux. Compte Microsoft + acceptation TOS.

planetarycomputer.microsoft.com 